Geração de Perguntas com Tópico Controlado: Proposta de Projeto

Tiago Lima Fraga — NUSP: 13859638

Artigo-base do projeto

LI, Z.; CUKUROVA, M.; BULATHWELA, S. A novel approach to scalable and automatic topic-controlled question generation in education. LAK 2025, Dublin: ACM, 2025.

POR QUE ESTE ARTIGO?

Comparação com os demais artigos levantados

	Gerador de Perguntas por Tópico (T-CQG) — escolhido	**Sistema de Tutoria Socrática com RAG (KITE)**	**Tutor com Grafo de Conhecimento (KG-RAG)**	**Corretor Automático de Provas (LLM-as-Judge)**
Dataset público	**Sim**	Não	Parcial	Não
Depende de LLM via API	**Não**	Sim	Sim	Sim
Envolve treinar um modelo (não só API)	**Sim**	Não	Não	Não
Avaliação humana é opcional, não obrigatória	**Sim**	Não	Não	Não

1. OBJETIVO DO ARTIGO SELECIONADO

Reduzir o trabalho do professor na criação de perguntas

- Criar perguntas por tópico é demorado para professores — contribui para sobrecarga de trabalho
- Método proposto (T-CQG — Gerador de Perguntas por Tópico): dado um contexto + um tópico-alvo, gera uma pergunta coerente e focada nesse tópico
- Diferencial: controla o sub-tópico específico, não apenas o tema geral (evita perguntas genéricas demais)
- Modelo leve, sem depender de LLMs proprietários — menor custo e mais privacidade

Como cada técnica foi usada no artigo

Fine-tuning / Transfer Learning

- Ajuste do T5-small pré-treinado (~60M parâmetros)

Geração condicionada (seq2seq)

- Entrada: contexto + tópico → saída: pergunta

Aprendizado contrastivo

- MixSQuAD combina contextos não relacionados para ensinar associação tópico-pergunta

Data augmentation

- MixSQuAD2X duplica exemplos invertendo a ordem dos contextos

Quantização (compressão)

- 8-bit e 4-bit reduzem o tamanho do modelo em memória

Métricas de PLN

- BLEU, ROUGE, METEOR, F1 + métrica própria (WikiSemRel)

No artigo, o modelo treinado com essas técnicas é chamado de "TopicQG"; a versão sem elas (usada como comparação) é o "baseline".

3. CONJUNTO DE DADOS UTILIZADO

Três datasets públicos, prontos para uso

SQuAD 1.1

100k+ perguntas sobre Wikipedia. Base de treino.

peS2o

Abstracts científicos. Pré-treino adicional.

KhanQ

1.034 perguntas STEM (Khan Academy). Avaliação.

Todos públicos — sem necessidade de coleta própria de dados.

4. CODIFICAÇÃO / IMPLEMENTAÇÃO

Pipeline de fine-tuning viável em uma única GPU

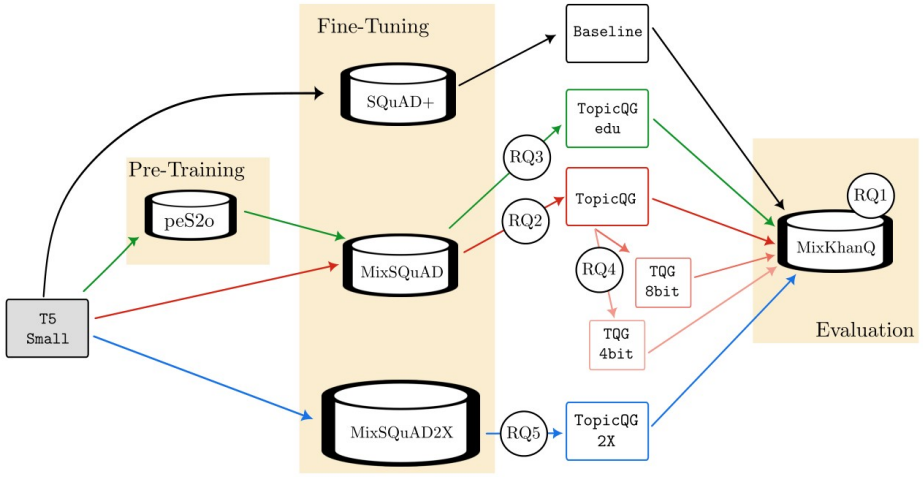


Fig. 2 do artigo — pipeline de treinamento e avaliação

- Construir SQuAD+ / MixSQuAD (linkagem de tópicos via Wikipedia)
- Fine-tuning do T5-small (Hugging Face Transformers)
- Avaliação automática no MixKhanQ
- Viabilidade: modelo pequeno — roda em GPU única ou Colab

4. CODIFICAÇÃO / IMPLEMENTAÇÃO

Seis variações do mesmo modelo, cada uma testando um ingrediente

A partir do mesmo modelo-base (T5-small), o artigo treina 6 versões — não são sistemas diferentes, só mudam um ingrediente de cada vez do treinamento:

Baseline

T5-small ajustado sem nenhuma técnica extra — o ponto de partida, usado só para comparação

TopicQG

Com aprendizado contrastivo — o modelo principal proposto no artigo

TopicQGedu

TopicQG + uma etapa extra de pré-treino em textos científicos

TopicQG 8-bit

TopicQG comprimido (quantização) para ocupar menos memória

TopicQG 4-bit

TopicQG comprimido ainda mais — testa o limite da compressão

TopicQG2X

TopicQG treinado com o dobro de dados (data augmentation)

Nenhuma dessas variações é um sistema separado — comparar entre elas é o que responde às perguntas de pesquisa do artigo (RQ1–RQ5).

Ganhos em relevância ao tópico

Resultados principais

- O modelo com a técnica (TopicQG) supera a versão simples (baseline) na maioria das métricas
- Quantização 8-bit: −59% de tamanho, perda mínima
- A versão com mais dados de treino (TopicQG2X): melhor relevância ao tópico

Como foram avaliados

- Métricas automáticas: BLEU, ROUGE, METEOR, F1
- Relevância ao tópico: BERTScore e WikiSemRel
- Validação humana: Kappa de Fleiss = 0,933

Por que isso importa

- Anotação humana confirmou WikiSemRel como métrica confiável — permite avaliar novos modelos sem repetir anotação humana

6. IDEIA PARA O PROJETO

Reproduzir o pipeline base e estender para controle de tópico

6.1 Etapa preliminar

- Baixar um conjunto público de perguntas e respostas já pronto
- Treinar uma versão simples do modelo, que gera perguntas sem se importar com o tópico
- Medir a qualidade das perguntas geradas com métricas automáticas padrão de linguagem
- Comparar esses números com os relatados no artigo, para confirmar que a reprodução está correta

6.2 Etapa final

- Criar exemplos de treino que ensinam o modelo a focar num tópico específico do texto
- Treinar essa nova versão e comparar com a versão simples da etapa anterior
- Extensão: Executar testes com LLMs proprietárias (Claude, GPT, Grok, etc.) e comparar métricas